

丁一芙

✉ eveedyf@gmail.com 📞 +86 18868001866 (☎ 微信同号) 🌐 个人主页 🎓 Google Scholar

博士研究生，聚焦大模型的推理加速、系统优化与模型压缩，研究低比特量化、剪枝、知识蒸馏、KV Cache 优化、高性能算子开发 (CUDA/Triton) 等算法与系统协同优化。在国际期刊会议发表论文 36 篇，含 ICML/ACL/NeurIPS/ICLR/CVPR/TPAMI 等，其中一作/共一/通讯 9 篇；论文引用 1.6K+，h-index 20，授权国家专利 2 项。



教育经历

新加坡南洋理工大学，计算与数据科学，访问博士，导师：陶大程教授	2024 年 11 月–2026 年 11 月
北京航空航天大学，计算机科学与技术，博士，导师：刘祥龙教授	2021 年 09 月–2026 年 12 月
北京航空航天大学，计算机科学与技术，本科。绩点：3.80/4.0；排名：25/257	2017 年 09 月–2021 年 07 月

代表性论文

高性能算子

- Accurate and Efficient Binarized Transformer by Algorithm-Hardware Co-design. **Y. Ding, X. Liu*, S. Jin, J. Guo, J. Lu. TPAMI** under review. [PDF] [Code]
 - ▶ 首个超低比特量化的高性能 CUDA 内核，支持二值、三值的线性层和注意力结构的各类矩阵乘法；
 - ▶ 相比 cuBLAS FP16 乘法实现**16–24 倍**单内核加速，在 2B LLMs 上预填充吞吐超过每秒 **80k** tokens。
- Diagonal-Tiled Mixed-Precision Attention for Efficient Low-Bit MXFP Inference. **Y. Ding, X. Zhang. EDGE @ CVPR 2026.** [PDF] [Code]
 - ▶ 设计基于 Triton 的 Micro-scaling Floating Point (MXFP) 混合精度注意力算子，提升低比特注意力计算精度；
 - ▶ 在 B200 GPU 上实现量化与注意力算子融合，在 LongBench 长上下文任务上精度**无损**。
- Low-bit FlashAttention Accelerated Operator Design Based on Triton. **J. Du, J. Guo, Y. Ding. ECLR @ ICCV 2025.** [PDF]
 - ▶ 设计基于 Triton 的混合精度 FlashAttention 内核，融合量化反量化与注意力机制；
 - ▶ 相比 FlashAttention2 实现**2.4 倍**单内核加速与**1.2 倍**端到端加速，同时保持模型精度。
- LAPrune: Logits-Aligned Scoring Proxy for KV Pruning via Vector Quantization. **M. Yu, R.-C. Tu, Y. Ding, H. Zhao, Y. Jing, X. Luo, D. Tao. NeurIPS 2026** under review. [PDF] [Code]
 - ▶ 提出基于加性向量量化的 KV Cache 剪枝框架，利用查表与标量累加构建高效注意力；
 - ▶ 实现 KV Cache 压缩**98%**时 LongBench 平均仅下降**1.0%**，128K 上下文较 FA2 解码加速**2.73 倍**。

模型压缩

- Attribution-Guided and Coverage-Maximized Pruning for Structural MoE Compression. **Y. Ding, J. Wang, G. Yang, Y. Jing, J. Guo, X. Liu, D. Tao. ICML 2026, Spotlight.** [PDF] [Code]
 - ▶ 提出部署友好的结构化剪枝与量化联合方案，实现混合专家模型 (MoE) 的高效压缩与部署；
 - ▶ 在问答、数学与代码推理等基准上保持**94.7%**原始精度，结合 4 比特量化实现**20 倍**吞吐与**5.27 倍**存储压缩。
- MAES: Modality-Aware Expert Slimming for Multimodal Mixture-of-Experts. **Y. Ding, Y. Jing, C. Wang, J. Huang, D. Tao. NeurIPS 2026** under review. [PDF]
 - ▶ 免训练的模态感知专家结构化剪枝框架，提出分块二阶海森矩阵的精确估计算法高效估计专家敏感性；
 - ▶ 在图像、视频理解任务上保持同压缩率性能领先，在 Qwen3-VL-30B-A3B 上**50%**剪枝下仍保留**92.9%**原始性能。
- QVGen: Pushing the Limit of Quantized Video Generative Models. **Y. Huang, R. Gong, J. Liu, Y. Ding, C. Lv, et al. ICLR 2026.** [PDF] [Code]
 - ▶ 设计量化误差抑制与渐进秩衰减模块，解决视频扩散模型低比特质量损失；
 - ▶ 首次在**4 个**主流模型上实现 4 比特生成质量与**全精度相当**。
- DA-KD: Difficulty-Aware Knowledge Distillation for Efficient Large Language Models. **C. He, Y. Ding, J. Guo, R. Gong, H. Qin, X. Liu. ICML 2025.** [PDF]
 - ▶ 提出分层难度感知蒸馏算法与双向差异损失，加速大模型知识蒸馏；
 - ▶ Qwen2.5-7B 蒸馏至 1.5B，蒸馏训练时间缩短**约 50%**，学生模型性能接近教师模型。
- A Survey of Low-Bit Large Language Models: Basics, Systems, and Algorithms. **R. Gong, Y. Ding, Z. Wang, C. Lv, X. Zheng, et al. Neural Networks 2025.** [PDF]
 - ▶ 全面综述大语言模型低比特量化技术，梳理**23 个**主流量化推理框架与**5 个**量化工具及评测基准，系统覆盖基础理

论、跨硬件系统支持及低比特训练与推理算法。

10. LLMCBench: Benchmarking Large Language Model Compression for Efficient Deployment. G. Yang, C. He, J. Guo, J. Wu, Y. Ding, A. Liu, H. Qin, P. Ji, X. Liu. **NeurIPS 2024, Spotlight**. [PDF] [Code]
▶ 构建压缩加速评测基准，覆盖**7种**剪枝/量化算法、**18个**大模型架构、**11个**数据集与**3类**主流推理平台。

推理加速

11. MrFlow: Multi-Resolution Flow Matching: Training-Free Diffusion Acceleration via Staged Sampling. X. Zheng, X. Liu, Y. Ding, W. Feng, J. Lin, J. Guo, H. Qin. 拟投稿 **ICLR 2027**. [PDF] [Code] [HF]
▶ 提出免训练的多分辨率分阶段采样框架，先低分辨率生成、Real-ESRGAN 超分、重编码并注入调度一致噪声，再进行短步高分率精修；
▶ 在 Qwen-Image 上实现**10.3倍**端到端加速，在 FLUX.1-dev 上实现**8.25倍**加速，结合 Pi-Flow 最高达**25倍**加速。
12. SPA-Cache: Singular Proxies for Adaptive Caching in Diffusion Language Models. W. Sun, R. Tu, Y. Ding, Z. Jin, J. Liao, S. Liu, D. Tao. **ICML 2026**. [PDF]
▶ 设计分层自适应缓存机制，使扩散语言模型高效复用 KV 缓存；
▶ 在 7 个数学与代码基准上，最高实现**8倍**吞吐，结合并行解码加速达**28倍**。
13. MoDES: Accelerating Mixture-of-Experts Multimodal LLMs via Dynamic Expert Skipping. Y. Huang, Z. Wang, Z. Yuan, Y. Ding, R. Gong, J. Guo, X. Liu, J. Zhang. **NeurIPS 2025**. [PDF] [Code]
▶ 免训练的模态感知专家跳过机制，利用双模态阈值动态选择激活专家，解决多模态 MoE 推理效率问题；
▶ Qwen3-VL 跳过**88%**专家，精度提升**10.67%**，预填充与解码分别加速**2.16倍**与**1.26倍**。
14. VORTA: Efficient Video Diffusion via Routing Sparse Attention. W. Sun, R. Tu, Y. Ding, et al. **NeurIPS 2025**. [PDF] [Code]
▶ 提出动态路由稀疏注意力，支持捕获长程上下文稀疏依赖，降低视频扩散模型长程注意力开销；
▶ 在 VBench 上实现**1.76倍**无损加速，结合缓存与蒸馏最高**14.4倍**加速。
15. Dynamic Parallel Tree Search for Efficient LLM Reasoning. Y. Ding, W. Jiang, S. Liu, Y. Jing, J. Guo, Y. Wang, J. Zhang, Z. Wang, Z. Liu, B. Du, X. Liu, D. Tao. **ACL (Main) 2025**. [PDF] [Code]
▶ 提出并行树思维链框架 (DPTS)，构建树状 KV 缓存并动态聚焦推理路径，提升数学与代码推理效率；
▶ 在数学推理与代码生成上实现**2—4倍**推理加速，精度与串行 MCTS 相当。

专业技能

模型压缩与加速：长期深耕模型量化、剪枝与知识蒸馏；系统研究 KV 缓存、解码策略与扩散加速；广泛探索大模型、多模态与视频生成的高效推理；具备从算法设计、算子实现、端到端部署与性能分析的全栈研发经验。

高性能算子：主导多个混合比特、稀疏化与算子融合等内核优化项目；熟练掌握基于 CUDA C++、Triton 及 FPGA 的定制化算子设计与编写、Nsight Systems 等性能分析工具；具备高性能 GPU 内核开发经验。

模型训练与部署：深入掌握 PyTorch、HF Transformers、TRL、PEFT、Unsloth、Accelerate、DeepSpeed、bitsandbytes、vLLM 进行模型训练及推理部署；具备低比特推理、模型吞吐与延迟优化及硬件感知部署经验。

学术服务

Workshop Chairs Program Chair, *ECLR @ ICCV 2025*; Local Arrangement Chair, *GLOW @ IJCAI 2024*; Publicity Chair, *EMCLR @ ACM MM 2024*.

学生编辑 参与编辑 Springer CCIS 论文集 *Generalizing from Limited Resources in the Open World*, 2024。

奖励与资助

博士研究生卓越学术基金，北京航空航天大学。人民币 40,000 元。	2025 年
国家留学基金，国家留学基金管理委员会。新加坡元 26,400 元（约 140,000 人民币）。	2024 年
研究生国家奖学金，中华人民共和国教育部。人民币 50,000 元。	2024 年
优秀学术成果奖，北京航空航天大学。	2023 年
博士研究生学业奖学金，一等奖，北京航空航天大学。	2022 年